



基于国产开源大模型的 AI Scientist 研发与应用

XH-202619 赛题汇报

RAD Group
上海交通大学

2026 年 5 月 27 日



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

报告提纲



-
- 1 赛题解读与核心挑战
 - 2 系统架构设计
 - 3 核心创新点
 - 4 工作计划（六月至八月）
 - 5 总结

1 赛题解读与核心挑战

2 系统架构设计

3 核心创新点

4 工作计划（六月至八月）

5 总结

赛题定位



赛题目标

面向具体学科领域，基于 Qwen 等国产大模型，研发能从「文献/数据输入」到「可验证科学假设输出」的 **AI Scientist** 系统。

技术载体

- 超级智能体框架：OpenClaw / Hermes / ARIS
- 多智能体编程架构（自主设计）
- 底座模型：Qwen（千问系列）

输出要求（标准化报告）

待研究问题	解决思路
标题 / 摘要	方法论
数据集	实验设计
实验结果	参考论文

选定领域：燃烧诊断与
高光谱反演（能源动力）

核心技术挑战



⚠ 三层难点

- 1 **文献事实抽取准确性**
需识别物理约束、实验参数、关键指标，不能仅做摘要归纳
- 2 **科学推理与幻觉防控**
假设须有真实证据锚点，每个引用可追溯至论文原句
- 3 **可验证的实验闭环**
评委要求：可复现 + 真实数据 + 代码，「看起来像科研」不得分

⚙ 模型能力差距

现实问题

Qwen（基线约 60 分）对比 GPT-5.5 / Claude opus 4.7（约 85 分）存在显著差距，尤其体现在：

- 复杂长文跨段推理
- 引用可信度与一致性
- 开放式科研创造力

核心命题：通过架构弥补模型能力差距，将系统综合能力提升至 75–80 分

1 赛题解读与核心挑战

2 系统架构设计

3 核心创新点


4 工作计划（六月至八月）

5 总结

总体架构：ARIS-Qwen 多智能体系统



底座模型
Qwen-Max
Qwen-Long



输出：标准化《科学假设与研究计划》 待研究问题 / 方法论 / 数据集 / 实验设计 / 参考论文

六大 Agent 职责划分



Agent	核心职责	输出
Reader	PDF 解析；结构化事实抽取	事实库 JSON（问题/方法/数据/结果/局限）
Gap Finder	识别论文未解决问题与研究缺口	缺口列表 + 证据句 id
Hypothesis Generator	基于事实库生成候选假设（ $\times 20$ ）	候选假设集合
Skeptic	批判审查：逻辑断点、引用虚假、自洽性	修订意见 + 置信度分
Experiment Designer	Baseline / Metrics / 数据集 / 消融实验设计	实验计划文档
Reproducer	生成最小验证代码并执行；结果回填	运行结果 + 图表

赛题解读与核心挑战

系统架构设计

3

核心创新点

工作计划（六月至八月）

总结

创新点一：弱模型能力放大框架



设计理念

不依赖单一强模型，通过**架构替代能力**：
把「开放科研创造」拆解为多个窄任务，
每步仅要求 Qwen 完成局部推理。

五项关键机制：

- ① **结构化 RAG 事实库**——消除幻觉引用
- ② **多角色批判循环**——Skeptic 强制审查
- ③ **硬规则 Verifier**——证据链 / 数据集 / Baseline 校验
- ④ **$N = 20$ 采样 + 评分筛选**——Top-3 质量选优
- ⑤ **工具执行替代脑补**——代码跑结果回填

预期能力提升曲线：

配置	综合得分（估）
Qwen 裸跑	60
+ RAG 事实库	68-72
+ 多角色批判 + 评分器	73-76
+ 工具执行 + 实验回填	78-82
GPT-4o 参考水平	≈85

🚩 **核心叙事**：「国产开源模型 + 架构补偿」
接近强闭源模型效果，符合比赛主旨

创新点三：可验证假设生成与假设评分器



Scientific Hypothesis Score (SHS)

每个候选假设自动打分（0-10）：

维度	权重
创新性（与已有工作差异度）	25%
证据强度（事实库锚点数量）	25%
可验证性（能否设计实验）	20%
实验成本（数据集 / 算力）	10%
领域价值（燃烧工程意义）	10%
复现风险（代码依赖复杂度）	10%

可验证链路（核心设计）



创新点四：自动实验复现闭环（ARIS 模式）



参考：ARIS 开源框架

Auto-claude-code-research-in-sleep

核心思路：Agent 在无人值守状态下自动完成 Idea 发现 → 实验执行 → 论文写作全流程。

本方案借鉴其工作流，以 Qwen 替换 Claude Code，增加领域专用 skills 和 Verifier 层。

Li-2024 最小复现实验（可直接跑）：

- 复现 6 个径向投影下的 PBNN 前向辐射拟合
- 注入 10% 高斯噪声，验证反演鲁棒性
- 投影数量消融（2 / 4 / 6 个径向）
- 输出：误差曲线 + 温度场二维重建图

闭环流程：

论文解析 + 事实库构建



缺口识别 + 假设生成 (×20)



Skeptic 批判 + SHS 评分



实验设计 + 代码生成



执行运行 + 结果回填



标准化研究计划输出



赛题解读与核心挑战

系统架构设计

核心创新点

4

工作计划（六月至八月）

总结

整体工作安排



阶段	时间	工作内容
Phase 1 调研 + 设计	6 月 26 日—6 月 30 日	文献调研 (Li-2024 等 ≥ 15 篇); 确定燃烧诊断领域 skills 清单; 搭建 Qwen API / 百炼 + ARIS 框架开发环境; 设计 Agent 接口规范。
Phase 2 核心开发	7 月 1 日—7 月 15 日	实现 Reader / Gap Finder / Hypothesis Generator 三个 Agent; 建立 RAG 事实库 (HITEMP + 本地论文库); 完成 Li-2024 Demo (假设生成可跑通)。
Phase 3 验证闭环	7 月 16 日—7 月 31 日	实现 Skeptic + Verifier + SHS 评分器; 实现 Experiment Designer + Reproducer; 完成 Li-2024 最小复现实验 (PBNN 基线 + 噪声消融)。
Phase 4 集成 + 优化	8 月 1 日—8 月 10 日	端到端联调 (PDF 输入 $\rightarrow$ 研究计划输出); 领域专用 skills 精调; 人在回路测试与错误分析。
Phase 5 报告提交	8 月 11 日—8 月 15 日	撰写技术报告与演示材料; 录制 Demo 视频; 最终提交。

关键里程碑与交付物



里程碑节点

- 📅 **6 月 30 日**
环境就绪 + Agent 接口设计文档完成
- 📅 **7 月 15 日**
Li-2024 Demo 可输出至少 5 个带证据的候选假设
- 📅 **7 月 31 日**
Verifier + 最小复现实验通过; SHS 评分可用
- 📅 **8 月 10 日**
端到端系统稳定, 全自动运行 ≥ 3 篇不同论文测试通过
- 📅 **8 月 15 日**
提交材料 (报告 + 代码 + Demo 视频)

最终交付物

- **系统代码:** 可复现的 Agent 框架 (含 Qwen API 调用链路)
- **领域 skills 库:**
燃烧诊断 6 个专用 Agent 模块
- **Demo 报告:**
Li-2024 驱动的《科学假设与研究计划》
- **验证结果:**
PBNN 基线复现 + 新假设对比实验图表
- **技术报告:**
含创新点说明、实验结果、消融分析

1

赛题解读与核心挑战

2

系统架构设计

3

核心创新点

4

工作计划（六月至八月）

5

总结

方案亮点总结




上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

创新点

- 1 弱模型能力放大框架（架构补偿）
- 2 领域垂直：燃烧诊断专用 skills
- 3 Scientific Hypothesis Score
- 4 可验证假设链路（证据 → 实验 → 代码）

核心叙事

国产开源模型（Qwen）+ 多智能体架构
+
领域垂直化 = 可验证的 AI Scientist,
在工程领域科研场景下有实际价值。



谢谢



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

